

Introduction à Pandas



MonCoachData



- Dans cette section, nous allons faire un rapide cours intensif sur les bases de Pandas !
 - Pourquoi nous utilisons Pandas ?
 - Séries Pandas et DataFrames
 - Données manquantes
 - Méthodes GroupBy
 - Opérations
 - Exercices et Solutions

- Qu'est-ce que Pandas ?
 - Pandas est l'acronyme de **Panel-Data**.
 - C'est la bibliothèque la plus populaire pour le traitement des données en Python et elle est construite directement à partir de NumPy.

- Qu'est-ce que Pandas ?
 - Comme nous travaillerons continuellement avec des données dans ce cours, nous utiliserons Pandas pour lire nos données, nettoyer les données et même l'étape de feature engineering (étape pendant laquelle les données sont reformatées, traitées, enrichies ou calibrées)

- Qu'est-ce que Pandas ?
 - Pandas s'appuie sur certaines structures de données de base pour ses opérations :
 - Series
 - Tableau de données avec un index qu'on peut nommer
 - DataFrame
 - Une "matrice" de données avec un index et des colonnes étiquetés.

- Et si vous connaissez déjà un peu Pandas ?
 - Consultez l'exercice à la fin de cette section pour tester vos compétences, puis n'hésitez pas à parcourir les différentes vidéos sur Pandas pour revoir tout ce que vous avez pu oublier.



Pandas

- Il est vivement recommandé de regarder ceci :
 - pandas.pydata.org/pandas-docs/stable/



MonCoachData

Series Pandas



MonCoachData



- Une série Pandas est très similaire à un tableau NumPy, à l'exception de l'ajout d'un index nominatif.
- Nous pouvons utiliser cet index nommé pour saisir les données du tableau.
- Voyons comment cela fonctionne avec Python.

DataFrames Pandas



MonCoachData



- Le DataFrame Pandas est notre principal outil pour travailler avec des données.
- Un DataFrame est simplement un ensemble de plusieurs Séries Pandas partageant le même index.
- Vous pouvez considérer un DataFrame comme étant similaire à un tableur, mais beaucoup plus puissant !

Données Manquantes



- Les ensembles de données issus du monde réel comportent souvent des données manquantes.
- En réalité, il n'y a que trois façons de traiter les données manquantes :
 - Laisser les données comme étant manquantes
 - Supprimer les données manquantes
 - Compléter les données manquantes

- Laisser les données comme étant manquantes :
 - Selon le type de données, il s'agit d'un choix valable.
 - Par exemple, s'il s'agit de données catégorielles, nous pourrions simplement traiter un NaN comme une autre catégorie.

- Supprimer les données manquantes :
 - Dépend de la quantité de données manquantes.
 - Pourcentage élevé - il manque trop de données pour pouvoir faire une estimation raisonnable
 - Faible pourcentage - ne supprime que quelques points de données de notre ensemble de données

- Compléter les données manquantes :
 - Un pourcentage non trivial de données manquantes et les lignes de points de données sont importantes
 - Il existe de nombreuses stratégies :
 - Mode, Moyenne, Médiane
 - Sur la base d'une autre colonne de caractéristiques (feature), vous pouvez concevoir une valeur adaptée.

- Traitement des données manquantes :
 - "Quelle est la bonne approche ?"
 - Tous les ensembles de données et toutes les situations sont différents !
 - Utilisez votre bon sens et vos objectifs généraux pour déterminer quelle stratégie est la bonne.

GroupBy



MonCoachData



- Souvent, nous voulons explorer comment les valeurs sont distribuées ou agrégées à travers des groupes.
- Pour ce faire, nous utilisons la méthode groupby, similaire à une requête GROUP BY en SQL.
- Ce processus est aussi souvent appelé Séparer-Appliquer-Combiner



Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8




Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8



Pandas

Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8



Col 1	Col 2
A	2
A	4
A	6

Col 1	Col 2
B	1
B	8

Col 1	Col 2
C	5
C	3



MonCoachData



Pandas

Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8

Col 1	Col 2
A	2
A	4
A	6

Col 1	Col 2
A	12

Col 1	Col 2
B	1
B	8

Col 1	Col 2
B	9

Col 1	Col 2
C	5
C	3

Col 1	Col 2
C	8



MonCoachData

Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8

Col 1	Col 2
A	2
A	4
A	6

Col 1	Col 2
A	12

Col 1	Col 2
B	1
B	8

Col 1	Col 2
B	9

Col 1	Col 2
C	5
C	3

Col 1	Col 2
C	8

Col 1	Col 2
A	12
B	9
C	8

Col 1	Col 2
A	2
B	1
A	4
C	5
A	6
C	3
B	8

Col 1	Col 2
A	2
A	4
A	6

Col 1	Col 2
A	12

Col 1	Col 2
B	1
B	8

Col 1	Col 2
B	9

Col 1	Col 2
C	5
C	3

Col 1	Col 2
C	8

Col 1	Col 2
A	12
B	9
C	8

- L'opération choisie avec un `groupby()` doit être une méthode d'agrégation.
- Cela signifie qu'elle peut prendre plusieurs valeurs et les combiner pour retourner une valeur unique.
 - Sum, Std, Mean, Count, Max, Min, etc...
- Apprenons à utiliser `groupby` avec Pandas !

Les opérations Pandas



MonCoachData



- Dans cette vidéo, nous allons passer en revue quelques opérations très utiles qui n'avaient pas leur place dans les vidéos précédentes !

Data Input et Output



MonCoachData

- Dans ce cours, nous lirons nos ensembles de données à partir de fichiers CSV, mais les données issues du monde réel peuvent provenir de diverses sources.
- Heureusement, Pandas dispose de solides outils IO (Input Output) que nous pouvons utiliser.
- Voyons quelques-uns d'entre eux en action et explorons la documentation qui leur est destinée

Pandas Exercices



MonCoachData



Pandas Solutions Exercices



MonCoachData