

Qu'est-ce que le Machine Learning?



MonCoachData



- Avant de nous lancer dans les réseaux de neurones (Neural Networks), TensorFlow, l'API Keras, etc... il est bon de comprendre certaines idées fondamentales concernant le Machine Learning.
- Dans cette section, nous allons donc aborder quelques théories et concepts importants du Machine Learning.





- Aperçu de la Section:
 - Qu'est-ce que le Machine Learning?
 - Qu'est-ce que le Deep Learning?
 - Différence entre l'Apprentissage Supervisé et Non Supervisé
 - Processus d'Apprentissage Supervisé
 - Évaluer les performances
 - Overfitting





Qu'est-ce que le Machine Learning ?

- Le Machine learning est une méthode d'analyse de données qui automatise la construction de modèles analytiques.
- En utilisant des algorithmes qui apprennent itérativement à partir de données, le Machine Learning permet aux ordinateurs de trouver des informations cachées sans être explicitement programmés pour savoir où chercher.





À quoi sert le Machine Learning ?

- Détection des fraudes
- Résultats de recherche sur le web
- Annonces en temps réel sur les pages web
- La notation de crédit
- Prévission des pannes d'équipement
- Nouveaux modèles de tarification
- Détection d'intrusion dans le réseau
- Moteurs de recommandation
- Segmentation de la clientèle
- Analyse de sentiment de texte
- Changement de client
- Reconnaissance de formes et d'images.
- Filtrage des courriers électroniques indésirables (SPAM)



Qu'est-ce que les réseaux de neurones ?

- Les réseaux de neurones sont un moyen de modéliser mathématiquement les systèmes de neurones biologiques.
- Ces réseaux peuvent ensuite être utilisés pour résoudre des tâches que beaucoup d'autres types d'algorithmes ne peuvent pas accomplir (par exemple, la classification d'images)
- Le Deep Learning fait simplement référence aux réseaux de neurones ayant plus d'une couche cachée.



- Il existe différents types de Machine Learning sur lesquels nous nous concentrerons au cours des prochaines sections du cours :
 - **Apprentissage Supervisé** (Supervised Learning)
 - **Apprentissage Non Supervisé** (Unsupervised Learning)





Machine Learning

- Machine Learning
 - Modèles analytiques automatisés
- Réseaux de Neurones
 - Un type d'architecture de Machine Learning modelée sur les neurones biologiques
- Deep Learning
 - Un réseau de neurones avec plus d'une couche cachée





- Commençons par nous familiariser avec l'une des tâches de Machine Learning les plus courantes : l'Apprentissage Supervisé !



Apprentissage Supervisé



MonCoachData



Apprentissage Supervisé

- Les algorithmes d'**Apprentissage Supervisé** sont entraînés à l'aide d'exemples **étiquetés**, comme une entrée où le résultat souhaité est connu.
- Par exemple, un segment de texte pourrait porter une étiquette de catégorie, telle que
 - **Spam** vs. Email **Légitime**
 - Critique de Film **Positive** vs. **Négative**





Apprentissage Supervisé

- Le réseau reçoit un ensemble d'entrées avec les sorties correctes correspondantes, et l'algorithme apprend en comparant sa sortie réelle avec les sorties correctes pour trouver les erreurs.
- Il modifie ensuite le modèle en conséquence.






Apprentissage Supervisé

- L'Apprentissage Supervisé est fréquemment utilisé dans les applications où les données historiques permettent de prédire des événements futurs probables.





Processus du Machine Learning





Processus du Machine Learning

- Obtenez vos données ! Clients, Capteurs, etc...


Acquisition
des Données






Processus du Machine Learning

- Nettoyez et formatez vos données (en utilisant Pandas)






Processus du Machine Learning






Processus du Machine Learning






Processus du Machine Learning






Processus du Machine Learning





Processus du Machine Learning





Apprentissage Supervisé

- Ce que nous venons de montrer est une approche simplifiée de l'Apprentissage Supervisé, il contient un problème !
- Est-il correct d'utiliser notre seul fractionnement des données pour évaluer les performances de nos modèles ?
- Après tout, nous avons eu la possibilité de mettre à jour les paramètres du modèle encore et encore.





- Pour résoudre ce problème, les données sont souvent divisées en **3 sets (ensembles)**
 - Les Données d'Entraînement (Training Data)
 - Utilisé pour entraîner les paramètres des modèles
 - Les Données de Validation (Validation Data)
 - Utilisé pour déterminer les hyperparamètres du modèle à ajuster
 - Les Données de Test (Test Data)
 - Utilisé pour obtenir une mesure finale de la performance





- Cela signifie qu'après avoir vu les résultats sur le **set final de test**, nous n'avons pas à revenir en arrière pour ajuster les paramètres du modèle !
- Cette dernière mesure est ce que nous appelons la véritable performance du modèle.





Apprentissage Supervisé

- Dans ce cours, en général, nous allons simplifier nos données en utilisant un simple **fractionnement train/test**.
- Nous allons simplement entraîner et ensuite évaluer sur un ensemble test (en laissant aux étudiants la possibilité de revenir en arrière et d'ajuster les paramètres).
- Après avoir suivi le cours, vous pourrez facilement effectuer un autre fractionnement pour obtenir **3 sets de données** si vous le souhaitez.



Overfitting et Underfitting



MonCoachData



- Maintenant que nous comprenons le processus complet de l'Apprentissage Supervisé, abordons les sujets importants suivants que sont **overfitting (sur-apprentissage)** et **underfitting (sous-apprentissage)**.






- **Overfitting (sur-apprentissage)**
 - Le modèle s'adapte trop au bruit des données.
 - Il en résulte souvent **un faible taux d'erreur sur les sets d'entraînement, mais un taux d'erreur élevé sur les sets de test/validation.**






Données






Bon Modèle






- **Overfitting**






- **Overfitting**






- **Overfitting**





- **Overfitting**






- **Underfitting (sous-apprentissage)**

- Le modèle ne saisit pas la tendance sous-jacente des données et ne correspond pas assez bien aux données.
- Faible variance mais biais élevé.
- L'Underfitting est souvent le résultat d'un modèle excessivement simple.






Données





Underfitting






- Ces données étaient faciles à visualiser, mais comment peut-on constater un underfitting et un overfitting lorsqu'on a affaire à des ensembles de données multidimensionnelles ?
- Imaginons d'abord que nous entraînons un modèle et que nous mesurons ensuite son erreur au cours de l'entraînement.






- Bon Modèle





Machine Learning


- Bon Modèle





Machine Learning

- Mauvais Modèle





- Lorsque nous envisageons les problèmes **overfitting (surapprentissage)** et **underfitting (sous-apprentissage)**, nous voulons garder à l'esprit la relation entre les performances du modèle sur l'ensemble d'entraînement par rapport à l'ensemble de test/validation.






- Imaginons que nous divisions nos données en un **set de training** et un **set de test**






- Nous voyons d'abord la performance sur le **set de training**






- Ensuite, nous vérifions les performances du **set de test**






- L'idéal serait que le modèle fonctionne bien dans les deux cas, avec un comportement similaire.





Machine Learning


- Mais que se passe-t-il si l'on “overfit” sur les données d’entraînement ? Cela signifie que nos performances seraient médiocres sur les nouvelles données de test !





Machine Learning


- Mais que se passe-t-il si l'on “overfit” sur les données d’entraînement ? Cela signifie que nos performances seraient médiocres sur les nouvelles données de test !





Machine Learning

- C'est une bonne indication d'un entraînement trop axé sur les données d'entraînement, vous devriez chercher le seuil sur le temps d'entraînement !





- Nous vérifierons à nouveau cette idée lorsque nous commencerons à créer des modèles !
- Pour l'instant, soyez simplement conscient de cette potentielle problématique !



Évaluation des performances

CLASSIFICATION





Évaluation du modèle

- Nous venons d'apprendre qu'une fois notre processus de Machine Learning est terminé, nous utilisons des mesures de performance (ou metrics) pour évaluer la qualité de notre modèle.
- Discutons plus en détail des mesures de classification !





Évaluation du modèle

- Les principaux paramètres de classification que nous devons comprendre sont les suivants :
 - Exactitude (Accuracy)
 - Rappel (Recall)
 - Précision (Precision)
 - F1-Score





Évaluation du modèle

- Mais d'abord, nous devons comprendre le raisonnement derrière ces mesures et comment elles fonctionnent en fait dans le monde réel !





Évaluation du modèle

- En règle générale, dans toute tâche de classification, votre modèle ne peut obtenir que deux résultats :
 - Soit votre modèle était **correct** dans sa prédiction.
 - Ou votre modèle était **incorrect** dans sa prédiction.





Model Evaluation

- Heureusement, l'opposition entre le correct et l'incorrect s'étend aux situations où vous avez plusieurs classes.
- Pour expliquer les métriques, imaginons une situation de **classification binaire**, où nous n'avons que deux classes disponibles.





Évaluation du modèle

- Dans notre exemple, nous allons essayer de prédire si une image est un chien ou un chat.
- Comme il s'agit d'apprentissage supervisé, nous allons d'abord **adapter/entraîner** un modèle sur les **données d'entraînement**, puis **tester** le modèle sur les **données de test**.
- Une fois que nous avons les prédictions du modèle à partir des données **X_test**, nous les comparons aux **vraies valeurs y** (les bonnes étiquettes/labels).





Évaluation du modèle

MODÈLE
ENTRAINÉ





Évaluation du modèle



**Image Test
de X_{test}**



MODÈLE
ENTRAINÉ





Évaluation du modèle



**Image Test
de X_{test}**

CHIEN

**Label Correct
de y_{test}**

**MODÈLE
ENTRAINÉ**





Évaluation du modèle



**Image Test
de X_{test}**

CHIEN

**Label Correct
de y_{test}**

**MODÈLE
ENTRAINÉ**

CHIEN

**Prédiction sur
Image Test**





Évaluation du modèle



**Image Test
de X_{test}**

MODÈLE
ENTRAINÉ

CHIEN

**Prédiction sur
Image Test**

CHIEN

**Label Correct
de y_{test}**



CHIEN == CHIEN ?

Compare la prédiction à l'étiquette correcte



Évaluation du modèle



**Image test
de X_{test}**

MODÈLE
ENTRAINÉ

CHAT

**Prédiction sur
Image Test**

CHIEN

**Label correct
de y_{test}**



CHIEN == CHAT ?

Compare la prédiction à l'étiquette correcte



Évaluation du modèle

- Nous répétons ce processus pour toutes les images de nos données de X_{test} .
- À la fin, nous aurons un nombre de correspondances correctes et un nombre de correspondances incorrectes.
- La principale constatation que nous devons faire, c'est que **dans le monde réel, toutes les correspondances incorrectes ou correctes n'ont pas la même valeur !**





Évaluation du modèle

- Dans le monde réel aussi, une seule mesure ne suffira pas à raconter toute l'histoire !
- Pour comprendre tout cela, reprenons les 4 mesures que nous avons mentionnées précédemment et voyons comment elles sont calculées.
- Nous pourrions organiser nos valeurs prédites par rapport aux valeurs réelles dans une **matrice de confusion**.





Évaluation du modèle

- Exactitude (Accuracy)
 - L'exactitude dans des problèmes de classification est le **nombre de prédictions correctes** faites par le modèle divisé par le **nombre total de prédictions**.





Évaluation du modèle

- Exactitude (Accuracy)
 - Par exemple, si l'ensemble X_{test} était de 100 images et que notre modèle a **correctement** prédit 80 images, alors nous avons **80/100**.
 - Ce qui donne une **exactitude** (ou **accuracy**) de **0.8** ou **80%**.





Évaluation du modèle

- Exactitude (Accuracy)
 - L'exactitude est utile lorsque les classes cibles sont bien équilibrées
 - Dans notre exemple, nous aurions à peu près la même quantité d'images de chats que d'images de chiens.





Évaluation du modèle

- Exactitude (Accuracy)
 - L'exactitude n'est **pas** un bon choix avec des classes **déséquilibrées** !
 - Imaginez que nous ayons 99 images de chiens et 1 image de chat.
 - Si notre modèle était simplement une ligne qui prédisait toujours **chien**, nous obtiendrions une justesse de 99% !





Évaluation du modèle

- Exactitude (Accuracy)
 - Imaginez que nous ayons 99 images de chiens et 1 image de chat.
 - Si notre modèle était simplement une ligne qui prédisait toujours **chien**, nous obtiendrions une exactitude de 99% !
 - Dans cette situation, nous voulons comprendre le **rappel** et la **précision**.





Évaluation du modèle

- Rappel (Recall)
 - Capacité d'un modèle à trouver tous les cas pertinents au sein d'un ensemble de données.
 - La définition précise du rappel est le nombre de vrais positifs (true positives) **divisé par** le nombre de vrais positifs plus le nombre de faux négatifs (false negatives).





Évaluation du modèle

- Précision (Precision)
 - Capacité d'un modèle de classification à identifier uniquement les points de données pertinents.
 - La Précision est définie comme le nombre de vrais positifs (true positives) divisé par le nombre de vrais positifs plus le nombre de faux positifs (false positives).





Évaluation du modèle

- Rappel et Précision
 - Il y a souvent un compromis à faire entre le Rappel et la Précision.
 - Alors que le Rappel exprime la capacité à trouver tous les cas pertinents dans un ensemble de données, la Précision exprime la proportion des points de données que notre modèle dit être pertinents et qui le sont bien en réalité.





Évaluation du modèle

- F1-Score
 - Dans les cas où nous voulons trouver un mélange optimal de précision et de rappel, nous pouvons combiner les deux mesures en utilisant ce que l'on appelle le score F1.





Évaluation du modèle

- F1-Score
 - Le score F1 est la moyenne harmonique du taux de précision et du rappel en tenant compte des deux métriques dans l'équation suivante :

$$F_1 = 2 * \frac{precision * recall}{precision + recall}$$





Évaluation du modèle

- F1-Score
 - Nous utilisons la moyenne harmonique au lieu d'une simple moyenne car elle sanctionne les valeurs extrêmes.
 - Un classificateur avec une précision de 1,0 et un rappel de 0,0 a une moyenne simple de 0,5 mais un score F1 de 0.





Évaluation du modèle

- Nous pouvons également visualiser toutes les images correctement classées par rapport aux images mal classées sous la forme d'une matrice de confusion.





Matrice de confusion

		predicted condition	
		prediction positive	prediction negative
true condition	condition positive	True Positive (TP)	False Negative (FN) (type II error)
	condition negative	False Positive (FP) (Type I error)	True Negative (TN)



Matrice de confusion

		predicted condition		
		total population		
			prediction positive	prediction negative
true condition	condition positive	True Positive (TP)	False Negative (FN) (type II error)	Prevalence $= \frac{\Sigma \text{condition positive}}{\Sigma \text{total population}}$
	condition negative	False Positive (FP) (Type I error)	True Negative (TN)	True Positive Rate (TPR), Sensitivity, Recall, Probability of Detection $= \frac{\Sigma \text{TP}}{\Sigma \text{condition positive}}$ False Positive Rate (FPR), Fall-out, Probability of False Alarm $= \frac{\Sigma \text{FP}}{\Sigma \text{condition negative}}$
		Accuracy $= \frac{\Sigma \text{TP} + \Sigma \text{TN}}{\Sigma \text{total population}}$	Positive Predictive Value (PPV), Precision $= \frac{\Sigma \text{TP}}{\Sigma \text{prediction positive}}$	False Omission Rate (FOR) $= \frac{\Sigma \text{FN}}{\Sigma \text{prediction negative}}$
		False Discovery Rate (FDR) $= \frac{\Sigma \text{FP}}{\Sigma \text{prediction positive}}$	Negative Predictive Value (NPV) $= \frac{\Sigma \text{TN}}{\Sigma \text{prediction negative}}$	Positive Likelihood Ratio (LR+) $= \frac{\text{TPR}}{\text{FPR}}$ Negative Likelihood Ratio (LR-) $= \frac{\text{FNR}}{\text{TNR}}$



Évaluation du modèle

- Le point principal à retenir avec la matrice de confusion et les différentes mesures calculées est qu'elles sont toutes fondamentalement des moyens de comparer les valeurs prédites aux valeurs réelles.
- Ce qui constitue de "bonnes" metrics, dépendra vraiment de la situation spécifique!





Évaluation du modèle

- Toujours confus sur la matrice de confusion ?
- Pas de problème ! Consultez la page Wikipédia pour en savoir plus, elle contient un très bon diagramme avec toutes les formules pour tous les paramètres.
- Tout au long de ce cours, nous nous contenterons généralement d'imprimer des mesures (par exemple, accuracy).





Évaluation du modèle

- Repensons à cette idée de :
 - Qu'est-ce qu'une précision suffisante ?
- Tout dépend du contexte de la situation !
- Avez-vous créé un modèle pour prédire la présence d'une maladie ?
- La présence de la maladie est-elle bien équilibrée dans la population générale ?
(Probablement pas !)





Évaluation du modèle

- Les modèles sont souvent utilisés comme des tests de diagnostic rapide à effectuer avant de procéder à un test plus invasif (par exemple, une analyse d'urine avant une biopsie)
- Nous devons également réfléchir aux enjeux !





Évaluation du modèle

- Souvent, nous avons un compromis entre précision et rappel. Nous devons décider si le modèle doit se concentrer sur la correction des faux positifs ou des faux négatifs.
- En matière de diagnostic des maladies, il est probablement préférable d'aller dans le sens des faux positifs. Nous veillons donc à classer correctement le plus grand nombre possible de cas de maladie !





Évaluation du modèle

- Tout cela pour dire que le Machine Learning n'est pas effectué dans un "vase clos", mais plutôt un processus de collaboration où nous devrions consulter des experts dans le domaine (par exemple des médecins)



Évaluation des performances

REGRESSION



MonCoachData





Évaluation de la régression

- Prenons maintenant un moment pour discuter de l'évaluation des modèles de régression
- La régression est une tâche lorsqu'un modèle tente de prédire des valeurs continues (contrairement aux valeurs catégorielles, qui sont des classifications)





Évaluation de la régression

- Vous avez entendu parler de certains paramètres d'évaluation comme la précision ou le rappel.
- Ce genre de métrique n'est pas utile pour les problèmes de régression, nous avons besoin de métriques conçues pour des valeurs **continues** !





Évaluation de la régression

- Par exemple, tenter de prévoir le prix d'une maison compte tenu de ses caractéristiques (features) est une **tâche de régression**.
- Tenter de prévoir le pays dans lequel se trouve une maison compte tenu de ses caractéristiques (features) serait une tâche de classification.





Évaluation de la régression

- Examinons quelques-unes des mesures d'évaluation les plus courantes pour la régression :
 - Erreur Absolue Moyenne (Mean Absolute Error - MAE)
 - Erreur quadratique moyenne (Mean Squared Error - MSE)
 - Racine carrée de l'erreur quadratique moyenne (Root Mean Square Error - RMSE)





Évaluation de la régression





- Erreur Absolue Moyenne - Mean Absolute Error (MAE)
 - C'est la moyenne de la valeur absolue des erreurs.
 - Facile à comprendre

$$\frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$



Évaluation de la régression


- Cependant, le MAE ne sanctionne pas les grosses erreurs.





Évaluation de la régression


- Cependant, le MAE ne sanctionne pas les grosses erreurs.





Évaluation de la régression

- Nous voulons que nos mesures d'erreur en tiennent compte !





Évaluation de la régression

- Erreur quadratique moyenne - Mean Squared Error (MSE)
 - C'est la moyenne des erreurs au carré.
 - Les erreurs plus importantes sont plus marquées qu'avec le MAE, ce qui rend le MSE plus populaire.

$$\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



Évaluation de la régression

- Racine carrée de l'erreur quadratique moyenne - Root Mean Square Error (RMSE)
 - C'est la racine de la moyenne des erreurs au carré.
 - Le plus populaire (a les mêmes unités que y)

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$



- Question la plus fréquente des étudiants :
 - "Cette valeur de RMSE est-elle bonne ?"
- Le contexte est essentiel !
- Une RMSE de 10 \$ est fantastique pour prédire le prix d'une maison, mais horrible pour prédire le prix d'une barre chocolatée !





Machine Learning

- Comparez votre mesure d'erreur à la valeur moyenne de l'étiquette dans votre ensemble de données pour essayer d'avoir une intuition de sa performance globale.
- La connaissance du domaine joue également un rôle important ici !



Apprentissage Non Supervisé



MonCoachData





- Nous avons couvert l'apprentissage supervisé, où **l'étiquette était connue** grâce à des **données historiques étiquetées**.
- Mais que se passe-t-il lorsque nous n'avons pas d'étiquettes historiques (ou labels) ?





- Certaines tâches relèvent de l'apprentissage non supervisé :
 - Clustering (regroupement)
 - Détection d'anomalies
 - Réduction de la dimensionnalité





- Clustering
 - Regroupement des points de données **non étiquetés** en catégories/clusters (groupes)
 - Les points de données sont attribués à un groupe en fonction de leur similarité





- Détection des anomalies
 - Tentatives de détection des valeurs aberrantes dans un ensemble de données
 - Par exemple, les transactions frauduleuses sur une carte de crédit





- Réduction de la dimensionnalité
 - Techniques de traitement des données qui réduisent le nombre de caractéristiques dans un ensemble de données, soit pour la compression, soit pour mieux comprendre les tendances sous-jacentes au sein d'un ensemble de données.





- Apprentissage non supervisé
 - Il est important de noter qu'il s'agit de situations où nous n'avons **pas** la bonne réponse pour les données historiques !
 - Ce qui signifie que l'évaluation est beaucoup plus difficile et plus nuancée !





Processus non supervisé





- Plus tard dans le cours, nous explorerons les processus d'apprentissage non supervisés avec des structures de réseaux de neurones spécialisés, tels que les auto-encodeurs.

