

NLP avec Deep Learning





Deep Learning

- Voyons comment travailler avec des données textuelles en parallèle du Deep Learning !
- C'est une extension naturelle des séries temporelles et des réseaux de neurones récurrents dont nous venons de parler.





Deep Learning

- Nous allons créer un réseau de neurones qui générera de nouveaux textes à partir d'un corpus de données textuelles.
- Voir “The Unreasonable Effectiveness of RNNs” de Andrej Karpathy
- Comment cela va-t-il fonctionner ?





- Étant donné une séquence de chaîne d'entrée, prévoyez la séquence décalée d'un caractère vers l'avant.
 - **["h", "e", "l", "l"]**
 - **["e", "l", "l", "o"]**






- Le RNN basé sur les caractères va en fait apprendre la structure du texte.
- Dans notre exemple, nous utiliserons les œuvres de William Shakespeare en anglais.
- Nous verrons le réseau apprendre la structure de l'écriture des pièces et aussi l'espacement, **juste au niveau du caractère !**





Deep Learning





Deep Learning

- Étape 1 : Lire les données de texte
 - Nous pouvons utiliser des commandes python intégrées de base pour lire dans un corpus de texte des données sous forme de chaînes de caractères.
 - Notez que vous devez disposer d'un grand ensemble de données pour cela, au moins 1 million de caractères pour des résultats réalistes.





Deep Learning

- Étape 2 : Traitement de texte et Vectorisation
 - Le réseau de neurones ne peut pas prendre en charge les chaînes de caractères brutes, nous allons donc les coder chacune en un entier.
 - A : 1
 - B : 2
 - C : 3
 - ? : 55





Deep Learning

- Étape 3 : Création de batches
 - Nous utiliserons l'objet dataset de Tensorflow pour créer facilement des lots de séquences de texte.
 - ["h", "e", "l", "l", "o", " ", "m"]
 - ["e", "l", "l", "o", " ", "m", "y"]





Deep Learning

- Étape 3 : Création de batches
 - Nous voudrions utiliser des séquences suffisamment longues pour saisir la structure et les mots précédents.
 - Mais pas au point que la séquence ne soit plus qu'un bruit d'historique.





Deep Learning

- Étape 4 : Création du modèle
 - Nous utiliserons 3 couches
 - Embedding
 - GRU
 - Dense






- Étape 4 : Création du modèle
 - La couche Embedding transforme les entiers positifs (indices) en vecteurs denses de taille fixe.
Ex : $[[4], [20]] \rightarrow [[0.25, 0.1, 0.3], [0.6, -0.2, 0.9]]$
 - Il appartient à l'utilisateur de choisir le nombre de dimensions d'embedding.



- Étape 4: Création du modèle
 - GRU
 - Le GRU (Gated Recurrent Unit) est un type spécial d'unité de neurone récurrent.
 - Le GRU est comme la mémoire à court et long terme (LSTM) avec une porte d'oubli, mais il a moins de paramètres que la LSTM, car il n'a pas de porte de sortie.



Gated Recurrent Unit (GRU)



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$





Deep Learning

- Étape 4 : Création du modèle
 - Couche Dense
 - Un neurone par caractère.
 - Les étiquettes des caractères seront codées en one-hot encoding, de sorte que la couche dense finale produise une probabilité par caractère.





Deep Learning

- Étape 4 : Création du modèle
 - Couche Dense
 - La probabilité par caractère signifie que nous pouvons jouer avec en fonction de la "température" :
 - Choisir plus/moins souvent des caractères moins probables





Deep Learning

- Étape 5 : Entraînement du Modèle
 - Nous mettrons en place nos batches et veillerons à encoder nos étiquettes de caractères en one-hot encoding.





- Étape 6 : Générer un nouveau texte
 - Nous allons enregistrer les poids de nos modèles et vous montrer comment charger de nouveau les poids d'un modèle avec une taille de lot/batch différente afin de passer des exemples uniques.



C'est parti !

Génération de texte Avec Python et Keras

PARTIE 1



MonCoachData





Deep Learning

- Étape 1 : Les Données
 - Importer les principales bibliothèques
 - Importer le texte
 - Comprendre les caractères



Génération de texte Avec Python et Keras

PARTIE 2



MonCoachData





Deep Learning

- Étape 2 : Traitement du texte
 - Vectoriser le texte
 - Créer un dictionnaire d'encodage



Génération de texte Avec Python et Keras

PARTIE 3



MonCoachData





- Étape 3 : Création de Batches
 - Comprendre les séquences de texte
 - Utiliser les datasets Tensorflow pour générer des lots
 - Mélanger les lots



Génération de texte Avec Python et Keras

PARTIE 4



MonCoachData





Deep Learning

- Étape 4 : Création du modèle
 - Mettre en place une fonction de perte (loss)
 - Créer un modèle
 - Embedding
 - GRU
 - Dense



Génération de texte Avec Python et Keras

PARTIE 5



MonCoachData





- Étape 5 : Entraînement du Modèle
 - Nous allons rapidement montrer un exemple de la façon d'entraîner le modèle.
 - Nous vous montrerons également comment charger le fichier modèle sauvegardé que nous vous avons fourni.



Génération de texte Avec Python et Keras

PARTIE 6



MonCoachData





- Étape 6 : Génération de texte
 - Nous allons charger notre modèle
 - Ajuster la taille du lot à 1
 - Faire tourner une boucle qui génère un nouveau texte

